



UNIVERSITÉ
CAEN
NORMANDIE

Université de Caen
Normandie



IUT Grand Ouest Normandie

Pôle de Caen

Bachelor Universitaire de Technologie

Département Science des Données

BUT Science des Données
Deuxième année

Parcours Science des Données : Visualisation, conception d'outils décisionnels

Portfolio

Etude sur les acquis de mon expérience en BUT SD



Auteur

Sidy Babacar Diop

Année universitaire 2024-2025

SOMMAIRE

Introduction	3
SAÉ - Intégration de données dans un datawarehouse	4
SAÉ - Collecte automatisée de données web	5
SAÉ - Conformité réglementaire pour traiter les données	6
SAÉ - Description et prévision de données temporelle	7
SAÉ - Développement d'un composant d'une solution décisionnelle	8
SAÉ - Reporting d'une Analyse Multivariée	9
Forces et faiblesses : analyse réflexive	10
Les objectifs que je me fixe pour m'améliorer	10

Introduction

Bienvenue dans mon portfolio !

Ce document est la vitrine de mon travail et de mon apprentissage durant cette année en deuxième année de BUT Science des Données à travers six Situations d'Apprentissage et d'Évaluation (SAÉ). Chaque projet réalisé durant cette année a été l'occasion de développer mes compétences et d'explorer des outils.

En choisissant le parcours Visualisation et conception d'outils décisionnels, certaines SAÉ ont joué un rôle clé. Elles m'ont permis de travailler sur des tâches variées, comme la collecte et l'analyse de données ou encore la création de reportings à partir de bases de données relationnelles.

Ce portfolio a pour objectif de :

- Montrer la diversité des projets que j'ai réalisés et leur portée.
- Illustrer les compétences que j'ai développées dans des contextes variés.
- Partager les résultats concrets de mes efforts et de mon engagement.

Je vous invite donc à parcourir ces différentes réalisations afin de découvrir plus en détail les approches, les outils utilisés lors de ces SAÉ et visualiser les résultats obtenus.

Merci et bonne lecture.

SAÉ - Intégration de données dans un datawarehouse

Présentation du projet

Le projet vise à analyser les données fournies par Olist, le plus grand site e-commerce brésilien, qui connecte des petites entreprises à travers le pays en leur permettant de vendre leurs produits via Olist Store. Les données incluent des informations sur les commandes, les clients, les vendeurs, les produits, et les méthodes de paiement. Ce projet a été divisé en plusieurs étapes, allant de la modélisation des données à des analyses poussées accompagnées de visualisations, afin d'identifier des tendances et fournir des recommandations stratégiques.

Organisation du travail

Le projet s'est déroulé en deux phases principales : d'abord, la préparation des données avec Jupyter Notebook, où les données ont été nettoyées, structurées et enrichies avec des variables pertinentes. Ensuite, la visualisation et l'analyse ont été réalisées avec Qlik Sense, en créant des tableaux de bord interactifs et en intégrant des données géolocalisées pour des analyses approfondies.


Démarche

1. Préparation des données avec Jupyter Notebook : J'ai nettoyé les données en supprimant les colonnes inutiles et en filtrant uniquement les commandes livrées. Ensuite, j'ai créé des variables importantes, comme le délai de livraison et le montant total dépensé, pour enrichir l'analyse. Enfin, j'ai structuré les données en différents sous-ensembles pour faciliter le travail.
2. Visualisation et analyse avec Qlik Sense : J'ai conçu des dashboards interactifs pour explorer les tendances, comme les délais de livraison, les notes de satisfaction et les prix moyens par catégorie. J'ai également utilisé des données géolocalisées pour analyser les performances régionales et identifier São Paulo comme un état clé.

Conclusion

En combinant Jupyter Notebook pour la préparation des données et Qlik Sense pour la visualisation, ce projet a permis de :

- Identifier des tendances clés dans les commandes, les délais de livraison, et les notes de satisfaction.
- Mettre en avant les catégories de produits les plus rentables et les régions stratégiques pour Olist.
- Fournir des recommandations concrètes pour améliorer les performances logistiques et marketing.



SAÉ - Collecte Automatisée de Données Web

Présentation du projet

le domaine des marchés financiers, analyser les données boursières et les actualités influençant les entreprises est essentiel. Le projet «BourseTrack» a pour objectif de centraliser et structurer ces informations afin de suivre les performances financières des grandes entreprises sur les 100 derniers jours ouvrés.

L'objectif principal est de développer une interface web intuitive permettant aux utilisateurs d'examiner les fluctuations des données financières et des actualités associées, pour une analyse rapide des tendances économiques.

Organisation du travail


Afin d'assurer une gestion optimale du projet, les responsabilités ont été attribuées en fonction des compétences et des domaines maîtrisés de chaque membre. Une personne s'occupait de la gestion des APIs et collecte des données boursières (récupération des prix, volumes, actualités). Un autre la gestion de la base de données (stockage, nettoyage, calcul des indicateurs financiers). Le dernier le développement du site web (design, interface utilisateur, affichage des données et actualités). La répartition des tâches est essentielle pour garantir une organisation fluide et une gestion efficace du projet.

Démarche

La collecte des données a été réalisée à l'aide des APIs Alpha Vantage pour les données boursières et News API pour les actualités économiques. Ces données ont été sauvegardées localement en format CSV, permettant un accès rapide et une compatibilité avec divers outils. Une base de données relationnelle a ensuite structuré ces informations, avec deux tables principales : l'une dédiée aux entreprises et l'autre aux données financières, reliées par le symbole boursier. Enfin, un tableau HTML interactif a été développé pour afficher des indicateurs clés comme les prix moyens, la volatilité et les tendances, tout en permettant de trier les colonnes selon les besoins des utilisateurs.

Conclusion

Grâce à une gestion optimisée des données via CSV, des APIs fiables, et une base de données structurée, le projet « BourseTrack » offre une solution efficace pour le suivi des performances financières. L'interface web développée garantit une expérience utilisateur fluide et intuitive, répondant aux besoins d'analyse rapide et précise.



SAÉ - Conformité réglementaire pour traiter les données

Présentation du projet

Notre projet vise à simplifier et automatiser l'analyse des résultats des élections en France. Nous avons travaillé sur les données des élections européennes du 9 juin 2024, disponibles via l'INSEE et data.gouv.fr. L'objectif? Rendre l'analyse rapide, efficace, et accessible à tous.

Organisation du travail

Pour avancer efficacement, chaque membre de l'équipe a pris en charge une partie spécifique du travail :

- Préparer et organiser les données brutes des élections.
- Fusionner les fichiers et générer des exports Excel clairs et utilisables.
- Créer des graphiques et cartes pour rendre les données visuelles et faciles à comprendre.


Cette organisation a permis de traiter efficacement les données et de produire des outils de qualité.

Démarche

1. Organisation des Données : Les résultats des élections ont été récupérés sous forme de fichiers CSV. Ces fichiers ont été nettoyés, organisés et enrichis avec des informations supplémentaires, comme les départements et régions correspondants.
2. Génération d'un Fichier Excel : Un fichier Excel a été créé, avec un onglet dédié à chaque département. Ces onglets contiennent les résultats triés et filtrés pour inclure uniquement les informations pertinentes.
3. Visualisation : Des graphiques et cartes interactives ont été développés pour rendre les données plus accessibles. Par exemple, des histogrammes montrent clairement les résultats par candidat, tandis que des graphiques en barres illustrent les taux de participation et d'abstention.

Conclusion

Ce projet démontre qu'avec une bonne organisation et des outils adaptés, il est possible de transformer des données brutes en ressources exploitables et visuelles. Les fichiers générés et les visualisations facilitent l'analyse et la compréhension des résultats des élections, offrant une solution efficace et accessible.



SAÉ - Description et prévision de données temporelle

Présentation du projet

Le projet "Analyse des Séries Temporelles des Matières Premières" a pour but d'explorer les tendances des cotations de différentes matières premières collectées à partir du site [Investing.com](https://www.investing.com). Les matières premières (le café, le cacao, le jus d'orange, le sucre et le pétrole) jouent un rôle clé dans l'économie mondiale. Elles influencent les industries, les marchés financiers et les politiques économiques. Analyser l'évolution des prix de ces ressources au fil du temps permet de mieux comprendre leurs dynamiques, de prévoir leurs variations futures et de prendre les bonnes décisions.

Organisation du travail

Le projet a été mené par une équipe de quatre membres. Chacun a joué un rôle essentiel dans la réalisation du projet, en se répartissant les tâches liées à l'importation et au nettoyage des données, à l'analyse statistique, ainsi qu'à la création de visualisations et à la rédaction de la documentation. La bonne collaboration et l'utilisation efficace des outils ont permis d'assurer la qualité et la cohérence des résultats.

Démarche

La démarche suivie se résume aux étapes suivantes : extraction des données brutes depuis des fichiers PDF, structuration et nettoyage des données en vue de leur analyse, création de visualisations et interprétation des tendances avec des outils comme ggplot2, et modélisation statistique pour anticiper les variations futures.

Conclusion

L'analyse des cotations des matières premières sur différentes périodes et sous divers angles met en évidence des dynamiques distinctes influencées par des facteurs géopolitiques, climatiques et économiques mondiaux. Les principales matières premières étudiées (cacao, café, jus d'orange, pétrole et sucre) révèlent des comportements complexes, où les tendances générales de hausse des prix, observées particulièrement après 2020, semblent être liées aux perturbations mondiales causées par la pandémie de COVID-19, les crises géopolitiques, et les conditions climatiques extrêmes.




Fig. 13 - Prévision des cotations mensuelles du Brent avec bande de confiance à 95%

SAÉ - Développement d'un composant d'une solution décisionnelle

Présentation du projet

Le projet "Dynamic EcoDashboard" a pour but de créer un tableau de bord interactif pour aider les entreprises à mieux comprendre leurs données économiques. Ce tableau de bord transforme des données brutes en informations claires et faciles à utiliser, ce qui aide à prendre de meilleures décisions. En combinant PHP pour les calculs et JavaScript pour l'affichage, l'objectif est de proposer un outil simple et efficace pour suivre les indicateurs de performance et s'adapter à un monde économique en constante évolution. Ce projet a été réalisé par un groupe de trois étudiants (moi compris).

Organisation du travail

Le travail a été réparti entre les trois membres du groupe, chacun ayant une responsabilité spécifique. Je me suis occupé de la partie B, qui comprenait le développement des fonctionnalités principales, comme la gestion des données avec PHP et l'affichage dynamique avec JavaScript. Un autre membre a travaillé sur la **partie A**, qui concernait la collecte et la structuration des données utilisées dans le tableau de bord. Le troisième membre a contribué à différents aspects du projet, notamment les tests, l'intégration des éléments et l'amélioration de l'interface. Nous avons collaboré de manière autonome, sans chef de projet désigné, en organisant régulièrement des échanges pour coordonner nos efforts. GitHub nous a permis de sauvegarder et de partager notre travail tout au long du projet.

Démarche

Pour mener à bien ce projet, nous avons suivi une démarche claire et structurée. Nous avons commencé par analyser les besoins pour déterminer les indicateurs clés à intégrer dans le tableau de bord. Ensuite, les données nécessaires ont été collectées, nettoyées et organisées pour garantir leur qualité et leur pertinence. La partie technique a ensuite été développée : PHP a été utilisé pour manipuler les données, et JavaScript a permis de créer des graphiques interactifs ainsi qu'une interface conviviale. Chaque fonctionnalité a été testée et améliorée en fonction des retours, pour assurer un résultat final fonctionnel et agréable à utiliser. Ces étapes ont permis de résoudre les problématiques liées à l'analyse et à la visualisation des données de manière efficace.

Conclusion

Le projet "Dynamic EcoDashboard" a permis de concevoir un outil utile pour l'analyse et la visualisation des données économiques.

Dynamic EcoDashboard : Tableau de Bord Interactif pour l'Analyse de l'Économie Mondiale

Partie A - Sélection d'un pays et vue d'ensemble des indicateurs

Sélectionner un pays et une année

Choisir un pays :

France ▼

Choisir une année :

-- Toutes les années -- ▼

Afficher

Fiche récapitulative de France (1960-2018)

Région : Europe & Central Asia

PIB : 1203775754448.3 milliards

Taux de chômage : 9.84%

Espérance de vie : 76.25 ans

Taux de mortalité : 9.68%

Utilisation d'Internet : 41.11%

Densité de population : 106 hab/km²

SAÉ - Reporting d'une Analyse Multivariée

Présentation du projet

Ce projet porte sur l'analyse multivariée des données de la cohorte AGRICAN. L'objectif principal est d'identifier les expositions professionnelles des agriculteurs et d'étudier leurs impacts sur la santé à travers une analyse statistique avancée.

AGRICAN (AGRIculture et CANcer) est une cohorte épidémiologique française visant à étudier les liens entre les expositions agricoles et divers problèmes de santé, notamment les cancers et les maladies neurodégénératives.

Le projet se concentre sur :

- L'importation et le nettoyage des données,
- L'analyse statistique multivariée (ACP, CAH, etc.),
- La création de visualisations interactives pour présenter les résultats de manière intuitive.

Organisation du travail

Nous étions un groupe de 4 afin de réaliser ce projet dans les meilleures conditions. Nous avons utilisé GitHub pour une collaboration fluide.

Le projet a été structuré en quatre phases principales : la recherche des différentes variables afin de réaliser le script R, la préparation des données pour garantir leur qualité, l'analyse statistique pour en extraire des informations pertinentes, et la restitution sous forme de visualisations de table et de rapport.

Démarche

Dans un premier temps, les données ont été nettoyées pour éliminer les valeurs manquantes et aberrantes, ce qui a permis de garantir une base de travail fiable. Ensuite, des techniques comme l'ACP ont été utilisées pour réduire la dimensionnalité et explorer les relations entre les variables, tandis que la CAH a permis de regrouper les observations en clusters homogènes. Enfin, les résultats ont été présentés sous forme de table mettant en évidence les variables les plus influentes et les principales conclusions de l'analyse.

Conclusion

La réalisation de ce projet a permis de développer des compétences en analyse multivariée, en visualisation et en gestion de projet. Les résultats obtenus, grâce à une démarche structurée et collaborative, constituent une ressource précieuse pour la compréhension des données et la prise de décision.

	mpg	cyl	disp	hp	drat	wt
Mazda RX4	21.0	6	160.0	110	3.90	2.620
Mazda RX4 Wag	21.0	6	160.0	110	3.90	2.875
Datsun 710	22.8	4	108.0	93	3.85	2.320
Hornet 4 Drive	21.4	6	258.0	110	3.08	3.215
Hornet Sportabout	18.7	8	360.0	175	3.15	3.440
Valliant	18.1	6	225.0	105	2.76	3.460
Duster 360	14.3	8	360.0	245	3.21	3.570
Merc 240D	24.4	4	146.7	62	3.69	3.190
Merc 230	22.8	4	140.8	95	3.92	3.150
Merc 280	19.2	6	167.6	123	3.92	3.440

Forces et faiblesses : analyse réflexive

Compétences	Forces	Faiblesses
C1. Traiter des données à des fins décisionnelles	Bonne maitrise en gestion BDD, en HTML, CSS, JavaScript.	Gestion de certains package difficile
C2. Analyser statistiquement les données	Bonne maitrise de l'outil d'analyse statistique RStudio	Moin bonne maitrise de SAS
C3. Valoriser une production dans un contexte professionnel	Bonne maitrise des outils de production (Word, LaTeX, Excel, PowerBI)	
C4. Développer un outil décisionnel	Bonne maitrise PHP, HTML, CSS, JavaScript (Chart.js)	Difficulté utilisation API

TABLE 1 – Tableau des compétences, forces et faiblesses

Les objectifs que je me fixe pour m'améliorer

Afin de toujours avancer dans la bonne direction, c'est-à-dire toujours apprendre de ses erreurs et s'améliorer, je pourrais faire différents travaux de mon côté.

- Identifier les packages problématiques et suivre des tutos trouvables par exemple sur youtubes ou autres plateformes gratuite
- Travailler en autonomie sur des petits projets.
- S'exercer avec des APIs simples et accessibles, comme l'API OpenWeatherMap pour afficher les données météo ou une API publique de films.
- Explorer les fonctionnalités disponibles et pas vu en cours de PowerBI et créer des tableaux de bord plus avancés pour un projet académique ou personnel.

En suivant ces objectifs, je pourrai progressivement renforcer mes compétences et me préparer à des environnements professionnels tout en restant dans un cadre académique.